Geekbang>. ^{极客邦科技}

全球领先的技术人学习和交流平台







Geekbang».

Info@: | EGO NETWORKS | Stu@:



高端技术人员 学习型社交网络



实践驱动的IT职业 学习和服务平台

促进软件开发领域知识与创新的传播





[上海] 2015年10月15-17日



[北京] 2015年12月18日-19日



关注InfoQ官方微信 及时获取ArchSummit演讲视频信息

ArchSummit全球架构师峰会 深圳站2015

朋友圈技术之道

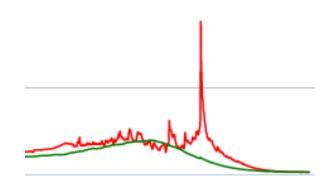


自我介绍

- 2012加入微信
- 负责
 - 帐号和关系链
 - 朋友圏
 - 消息

巨大的业务量

- 5.49亿微信MAU
- 朋友圈每天活跃量
 - 发表+赞+评论:过10亿
 - 浏览:过100亿
- 节日效应
 - 每个节假日都是一次狂欢:元旦、除夕、情人节、七夕、中秋、圣诞、 5/20、...
 - 节日流量:平时流量=2:1
- 突发效应
 - 零点:元旦、除夕、圣诞
 - 各类突发事件: 重大体育比赛、北京下雪了、...
 - 突发峰值:平时峰值=5:1



敏捷的开发速度

• 每个季度一个主要版本



• 每天后台不定期变更

基础环境

- 全部采用C++
 - 正往C++11迁移
- 混合部署的普通服务器
 - 8/16/24/32 cores w/ hyper-thread
 - 8/16/32G memory
 - Hard disk/SSD
- 海量带宽

"?"团队

现在流行小团队

- Instagram
- What's app
- **–** ..

"微"团队

- 人员增长了50%
- 从2位增长到3位



朋友圈"微"团队诚邀第"4"人加入

- 如果你想踏上移动互 联网的巅峰
- 如果你想服务全球亿 万用户
- 如果你想挑战世界 级的分布式系统技 术难题
- 如果你想和一群志 同道合的码农一起 愉快玩耍

请加入我们!





强大的基础设施:站在巨人的肩膀上

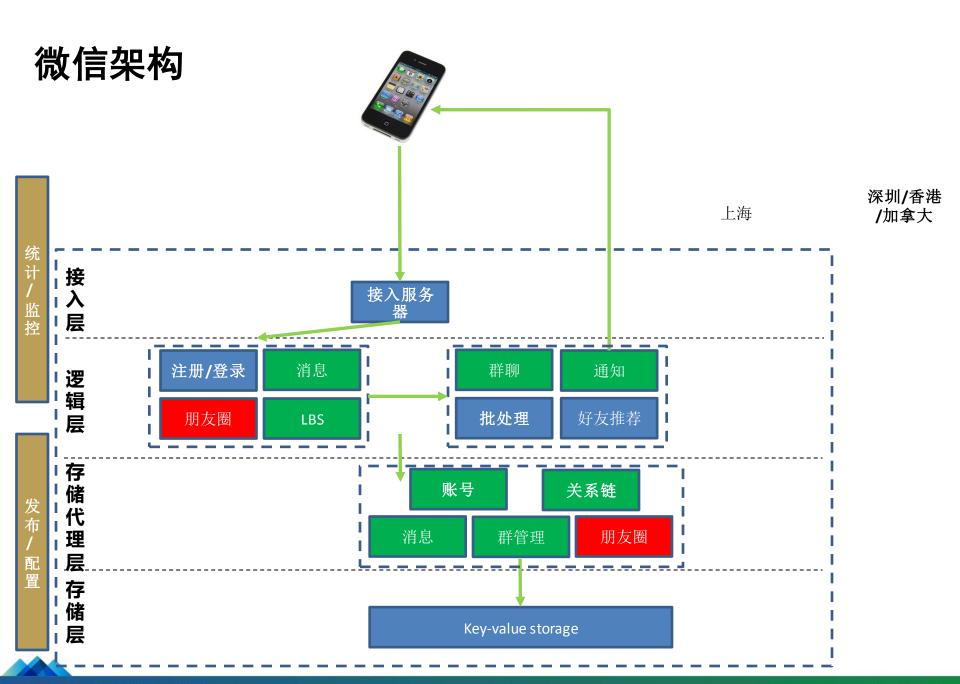
- 腾讯CDN
 - 图片和视频上载、存储、分发
- RPC 框架
- Key-value (KV)存储系统
- 强大、方便、灵活的部署系统

强大的RPC框架

- C++框架
- 支持protobuf描述接口
- 支持进程/线程/协程多种模式
 - 支持数十万的并发协程
 - 方便编写和调试"同步"的网络调用和服务
- 从CGI到叶子服务器,全系统透明支持过载保护和QoS
- 可为每次CGI调用自动生成全系统的调用关系图call graph
- 每个服务自动内建500多个监控项
 - 各个接口的客户端和服务器调用量
 - 接口耗时分布
 - 接口返回码分布
 - 当前QoS服务状况
 - **–** ...

高性能分布式key-value存储系统

- 三机一组
 - 三机间支持数据强一致性
 - 容忍一台机出错、自动切换
- 三机分布在一个数据中心的三个独立园区
 - 在任一园区提供本区读写服务
 - 容忍一个园区网络隔离
- 详情参见去年相关讲座



朋友圈架构



性能水平扩展

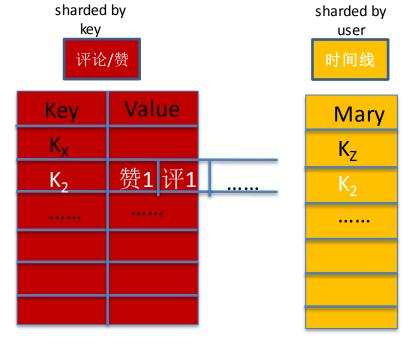
CDN

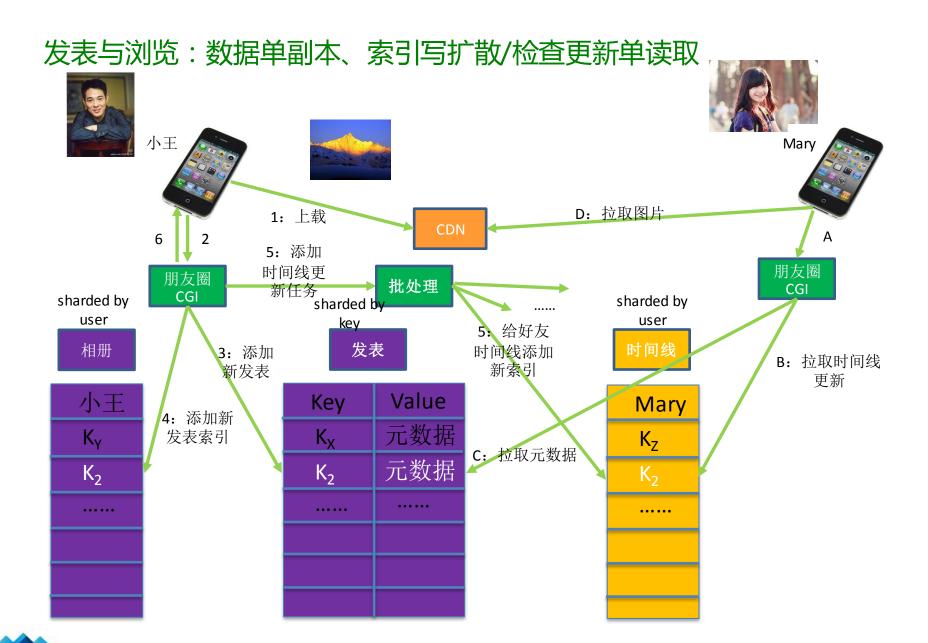
sharded by user

相册

小王 K_Y K₂ sharded by key 发表

| Key | Value |
|----------------|-------|
| K _X | 元数据 |
| K ₂ | 元数据 |
| | |
| | |
| | |
| | |

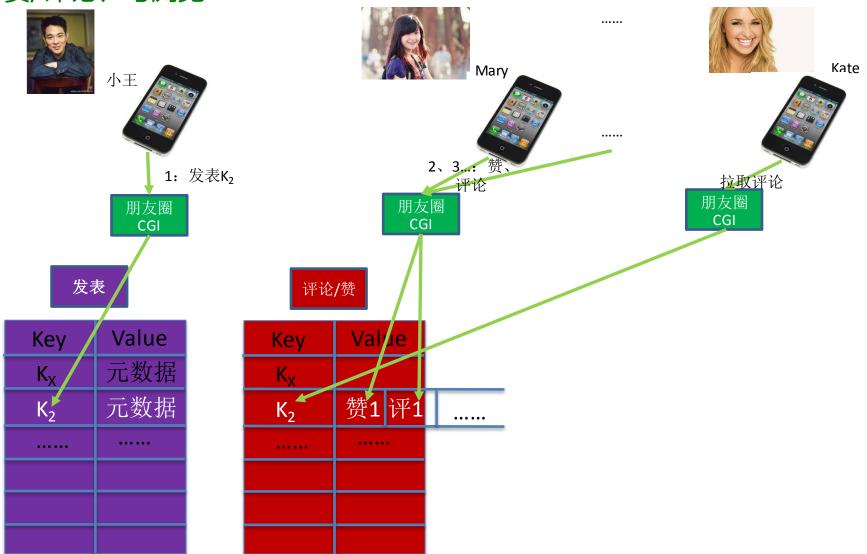




数据单副本、索引写扩散/检查更新单读取

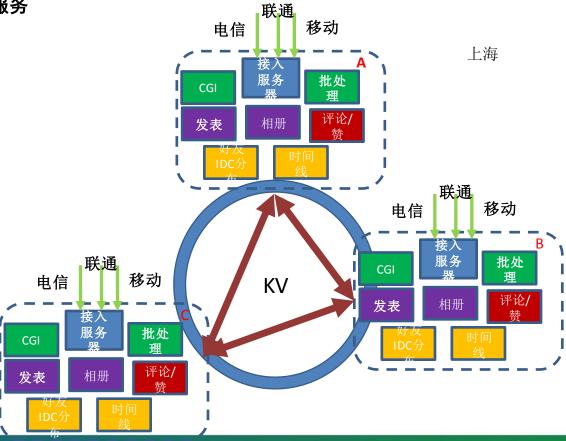
- 数据(发表)单副本:减少存储开销
- 索引写扩散/检查更新单读取:减少检查更新时的读扩散





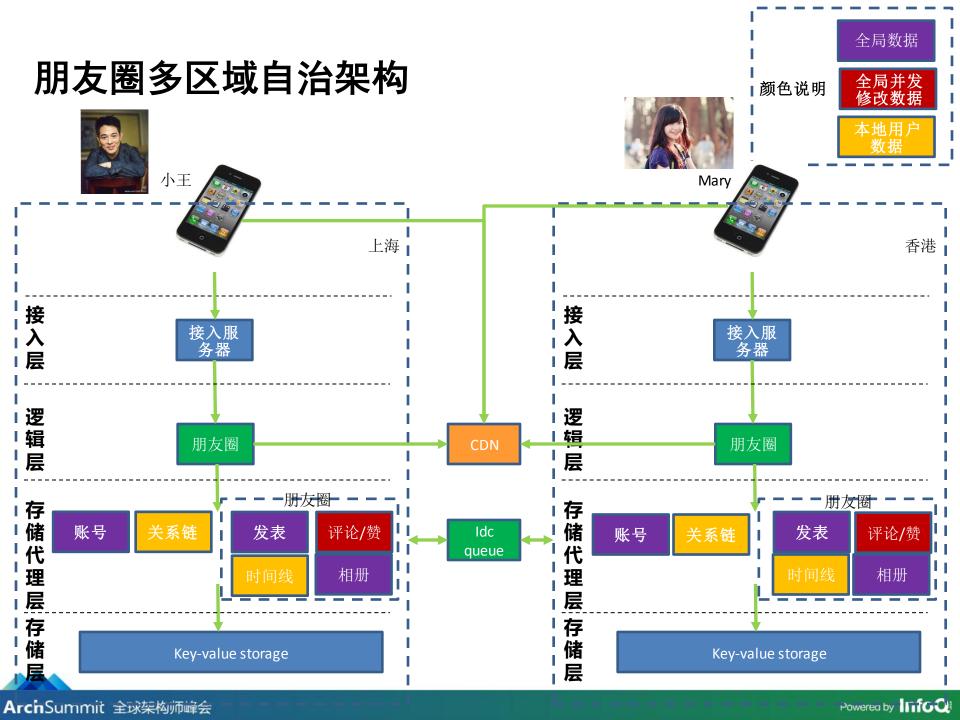
微信/朋友圈部署、接入、与容灾

- ▶ 1地3园区对等部署
 - > 对等接入:每个园区同时接入电信、联通、移动等运营商
 - > 数据对等分布与同步: KV提供园区数据对等部署与同步
 - > 对等服务:每个园区服务能力均等
- ➢ 容灾
 - 任何两个园区都可提供全量无损服务
- ▶ 优点
 - 提供完全无损的容灾体验
 - > 对逻辑层完全透明



从一地到全球:微信/朋友圈数据中心全球分布

每个区域独立服务本区域微信/朋友圈用户 专线 公网 (加密UDP) 国内 国外 中国北方 上海 美洲与欧洲 朋友圈 东南亚、南亚、 深圳 中国南方 香港 中东、非洲



核心数据读写分析

- 相册与发表
 - 本地idc写入、单向同步到其它idc
 - Key的全局唯一性保证无冲突
- 时间线
 - 本地idc只保存本地用户时间线的key, 无需同步



小王 上海

Mary

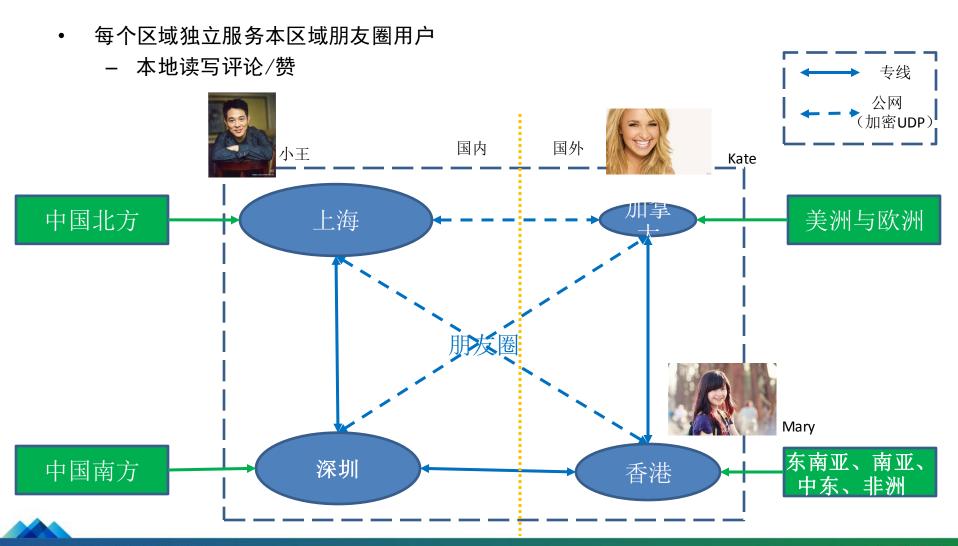
香港

| | sharded by user | s harded by key | | sharded by user | | sharded by user | | sharded by key | | sharded by user | |
|----|--------------------|--------------------|-------|--------------------|---------------|----------------------|--------------|-------------------|-------|--------------------|------|
| | 相册 | 发 | 表 | 时间线 | | l 相别 | } | 发表 | 表 | 时间线 | |
| | 小王 | Key | Value | 小王 | | 小 | Ŧ. | Key | Value | Mary | į |
| | K _Y | K _X | 元数据 | K _Z | 同步 | K _Y | | K _X | 元数据 | K _Z | ij |
| 表K | K ₂ | K ₂ | 一业业中 | К ₂ | 192 | → K ₂ | | ► K ₂ | 元数据 | K ₂ | |
| | | | | | | | | | | | H |
| | Mary | | | | | Mar | | | | | |
| | K ₃ | K ₃ < | | K ₃ | | 发: K ₃ | | ^{₹K3} K3 | | K ₃ | - 1 |
| | | | | | | | | | | | į |

跨洋同步的挑战与应对

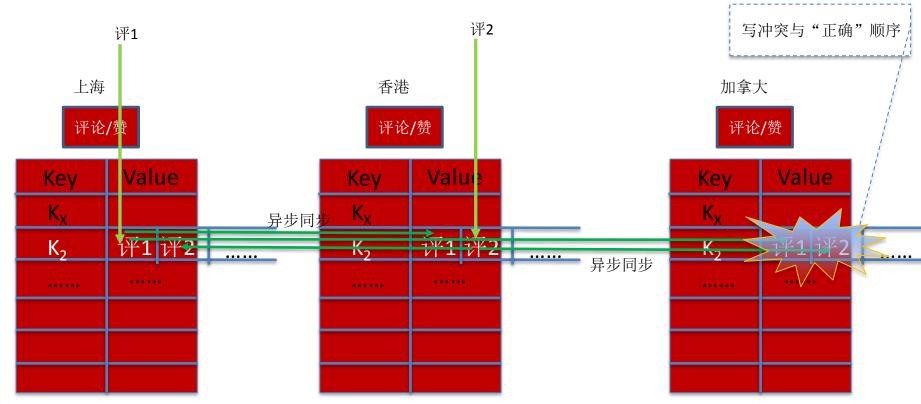
- 挑战
 - 大带宽高延迟
 - 国内 vs. 跨洋= 20-40 vs. 200-400ms RTT
 - 常见的丢包与乱序
 - 低可靠性:专线中断可预期
- 应对措施
 - 延迟、丢包、乱序达到一定程度时idc queue自动从TCP切换到UDP协议
 - 专线中断时自动切换到公网
 - AES加密

One More Thing

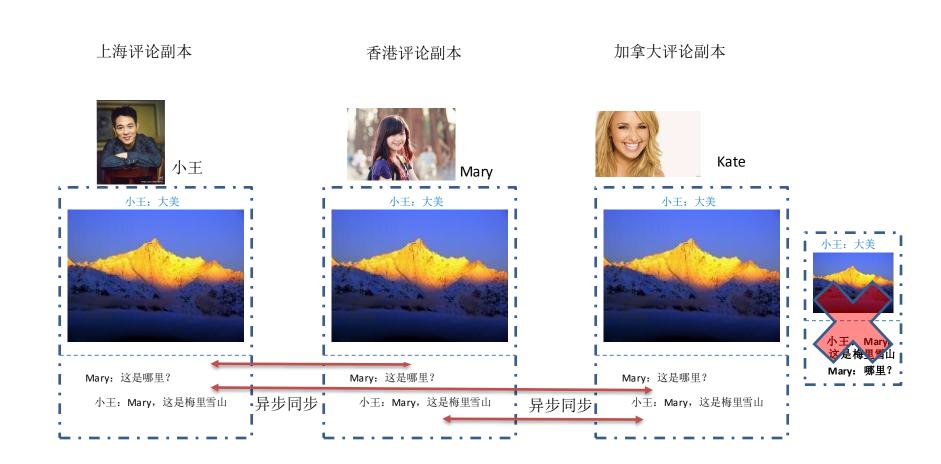


评论/赞的写冲突、"正确"顺序、与一致性

- 评论/赞
 - 本地写入
 - 异步双向同步到其它IDC



正确性与一致性



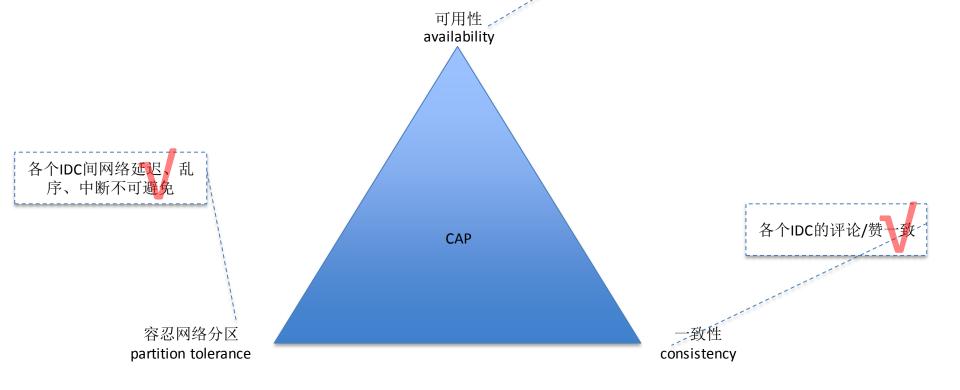
常见解决方案

- 1. 主-备同步
 - 1. 算法
 - 1. 每个key有一个主副本
 - 2. 评论/赞先写到主副本
 - 3. 主副本广播给次副本
 - 2. 优点:简单
 - 3. 缺点:存在单点失败的风险
- 2. 多点并行写入、按照评论/赞时间排序
 - 1. 算法
 - 1. 各个IDC本地写入、广播给其它IDC
 - 2. 客户端按照时间顺序展示评论/赞
 - 2. 优点:简单
 - 3. 缺点
 - 1. 分布式系统各个机器的时间不对齐、可能导致评论/赞乱序与相互覆盖
 - 2. 网络延迟可能导致前置评论暂时丢失
- 3. 中心锁
 - 1. 不予考虑

关键挑战

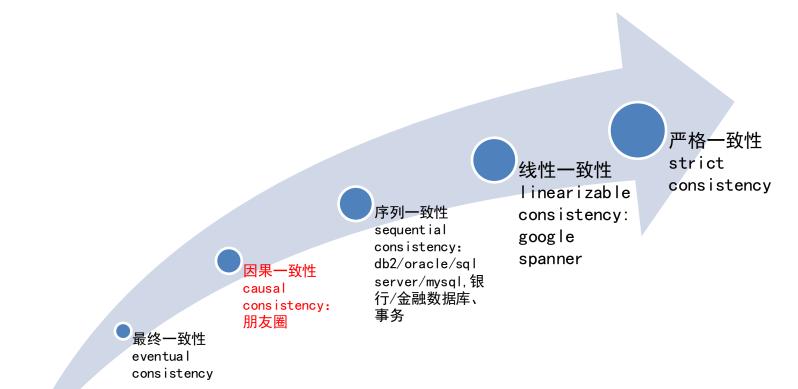
各个IDC的独立可评论/赞

在容忍IDC间网络分区的情况下,同时保证可用性与一致性



一致性

• 定义:一个对象的多个副本的数据一致

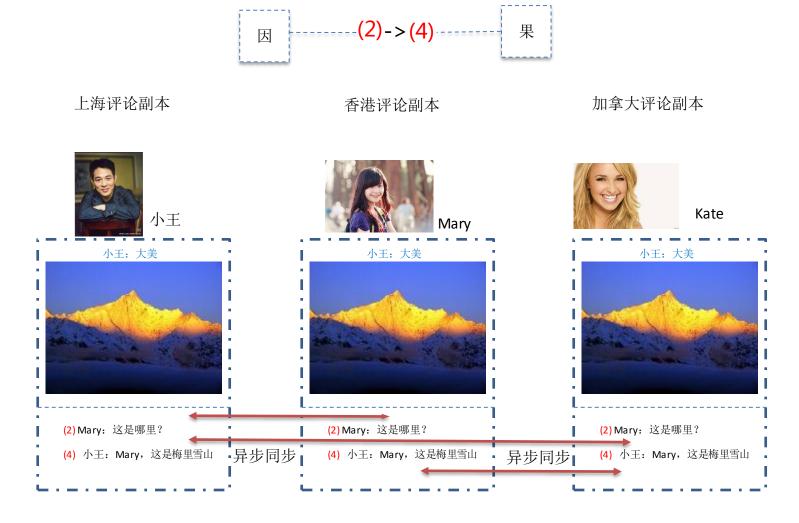


因果一致性

- 有因才有果
- 因发生在果之前
- 先看见因,才看见果
 - 先看见评论(因),才看见对此评论的回复(果)

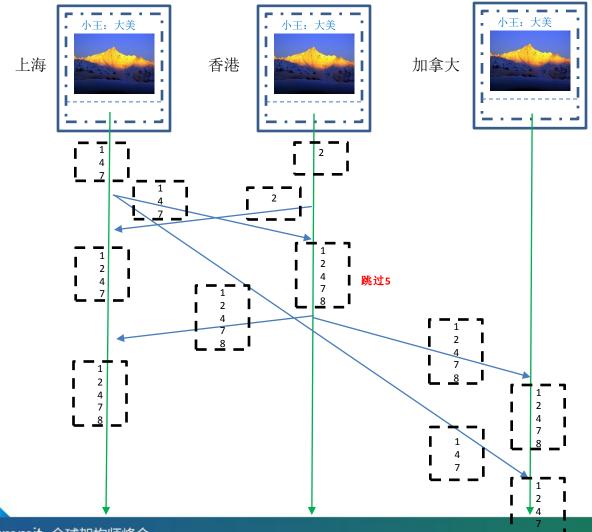


定因果



因果一致性算法

- ▶ 每条评论都有一个唯一的且递增的数字ID,确保排重
- ▶ 每条新评论的ID都必须比本地已经见过的全局最大的ID大,确保因果关系
- ▶ 广播本地看到的所有评论和新评论到其它IDC;相同ID的评论合并排重



- 1. Vector clock
- 2. Log-structure comments

Thanks!



朋友圈"微"团队诚邀第"4"人加入

- 如果你想踏上移动互 联网的巅峰
- 如果你想服务全球亿 万用户
- 如果你想挑战世界 级的分布式系统技 术难题
- 如果你想和一群志 同道合的码农一起 愉快玩耍

请加入我们!



